

머신러닝 깊게 이해하기

노트테이커: 김명석

주차: 2주차

일시: 6th, October

Ch 1.5 결정 이론 (p.42)

1. 결정 이론의 정의 및 역할

결정 이론은 패턴 인식 문제를 해결할 때처럼 불확실성이 존재하는 상황에서 의사 결정을 내려야 할 경우에 확률론과 함께 사용되어 최적의 의사 결정을 내릴 수 있도록 돕는다.

- 주어진 입력 벡터 $\mathbf{x}$ 에 대해 타깃 변수 t 를 예측하는 문제(회귀 또는 분류)를 생각할 때, 결합 확률 분포 $p(\mathbf{x}, t)$ 는 변수들의 전체 불확실성을 요약한다. 이 확률적 정보를 기반으로 특정 행동을 취해야 할 때, 어떻게 최적의 결정을 내릴 것인가를 설명하는 것이 결정 이론의 핵심 목표이다.
- 이 과정은 일반적으로 두 단계로 나뉜다:
 - 추론 단계 (Inference Stage):** 훈련 집합 데이터를 활용하여 조건부 확률 $P(C_k|\mathbf{x})$ 에 대한 모델을 학습시키는 단계이다. (또는 결합 확률 분포 $P(\mathbf{x}, C_k)$ 를 결정하는 단계)
 - 결정 단계 (Decision Stage):** 학습된 확률(사후 확률)을 이용하여 최적의 클래스 할당을 시행하는 단계이다. 적절한 확률들이 주어졌다면, 결정 단계는 비교적 간단하게 수행될 수 있다.

$$p(C_k | \mathbf{x}) = \frac{p(\mathbf{x} | C_k) p(C_k)}{p(\mathbf{x})} \quad (\text{식 1.77})$$

2. 분류 문제에서의 최적 결정 기준

결정 이론은 분류 문제에서 어떤 입력 $\mathbf{x}$ 를 어떤 클래스 C_k 에 할당할지 결정하는 기준을 제시한다.

1. 오분류 비율의 최소화 (Minimizing Misclassification Rate)

- 가장 단순한 목표는 잘못된 분류 결과의 숫자를 가능한 한 줄이는 것이다.
- 규칙:** 입력 공간을 클래스의 수만큼 결정 구역(R_k)으로 나눈다. R_k 에 속하는 모든 포인트는 클래스 C_k 로 분류됩니다. 이 구역들 사이의 경계가 결정 경계(decision boundary)이다.
- 최적의 결정 규칙:** 실수가 발생할 확률을 최소화하려면, 각각의 입력 $\mathbf{x}$ 를 사후 확률 $P(C_k|\mathbf{x})$ 가 최대가 되는 클래스에 포함시켜야 한다. (직관적으로 가장 확률이 높은 클래스를 고르는 것이다).

2. 기대 손실의 최소화 (Minimizing Expected Loss)

- 실제 응용 사례에서는 단순한 오분류 숫자 최소화보다 더 복잡한 목표를 가진다. 예를 들어, 암 환자 진단 문제에서 암에 걸린 환자를 건강하다고 잘못 진단하는 것(매우 심각함)과 건강한 환자를 암에 걸렸다고 잘못 진단하는 것(덜 심각함)은 그 결과가 다르다.
- 이러한 문제를 공식화하기 위해 손실 함수(Loss Function)(비용 함수, *Cost function*이라고도 불림)를 도입한다.
- 손실 함수:** 어떤 결정이나 행동이 일어났을 때의 손실을 측정하는 함수입니다. 목표는 발생하는 전체 손실을 최소화하는 것이다. (손실의 음의 값이 효용 함수이며, 이를 최대화할 수도 있다).
- 손실 행렬(L_{kj}):** 실제 클래스가 C_k 인데 입력 $\mathbf{x}$ 를 클래스 C_j 로 분류했을 때 발생하는 손실을 L_{kj} 로 표현한다. 예를 들어, 암 환자를 건강하다고 잘못 진단했을 때의 손실은 1,000으로, 건강한 환자를 암이라고 진단했을 때의 손실 1보다 훨씬 클 수 있다.

- **최적의 결정 규칙:** 손실 함수값은 실제 클래스값을 알아야 계산 가능하므로, 우리는 평균 손실(기대 손실 $E[L]$)을 최소화하는 것을 목표로 삼는다.
- 기대 손실을 최소화하는 결정 법칙은 각각의 $\mathbf{x}$ 를 다음 식 1.81을 최소화하는 클래스 j 에 할당하는 것이다:

$$\sum_k L_{kj} P(C_k | \mathbf{x}) \quad (\text{식 1.81})$$

3. 추가적인 결정 옵션 및 접근법

- **거부 옵션 (Rejection Option)**

- 입력 공간 중 일부 구역에서는 사후 확률 $P(C_k | \mathbf{x})$ 중 가장 큰 값조차 1보다 매우 작을 수 있다. 이는 결합 확률들이 비슷한 값을 가지고 있어 분류 오차가 생기기 쉬움을 의미하며, 이 지역에서는 분류에 대한 확신 정도가 비교적 적다.
- 오류 비율을 최소화하기 위해 **결정을 내리기 힘든 지역에 대해서는 결정을 피하는** 것이 적절할 수 있으며, 이를 거부 옵션이라고 한다.

- **결정 문제를 푸는 세 가지 접근법**

결정 문제를 해결하는 방식은 크게 세 가지로 나뉘며, 복잡한 방식부터 덜 복잡한 순으로 다음과 같다:

$$p(C_k | \mathbf{x}) = \frac{p(\mathbf{x} | C_k) p(C_k)}{p(\mathbf{x})} \quad (\text{식 1.82})$$

1. **생성 모델 (Generative Model):** 각각의 클래스 C_k 에 대한 조건부 확률 밀도 $P(\mathbf{x} | C_k)$ 와 사전 확률 $P(C_k)$ 를 구한 후, 베이저안 정리(식 1.82)를 적용하여 사후 확률 $P(C_k | \mathbf{x})$ 를 계산한다. 사후 확률을 구한 후에 결정 이론을 적용한다. 이 방식은 결합 분포 $P(\mathbf{x}, C_k)$ 를 모델링하며, 컴퓨팅 자원의 낭비일 수 있지만, 데이터의 주변 밀도를 구할 수 있어 outlier detection에 유용하다.

2. **판별 모델 (Discriminative Model):** 사후 확률 $P(C_k|\mathbf{x})$ 를 직접 모델링한 후 결정 이론을 적용하여 클래스를 구한다. 이는 생성 모델보다 효율적일 수 있다.
3. **판별 함수 (Discriminant Function):** 입력값 $\mathbf{x}$ 를 클래스에 직접 사상하는 함수 $f(\mathbf{x})$ 를 찾는다. 이 방식은 추론 단계와 결정 단계를 하나의 학습 문제로 합친 것이며, 확률론이 사용되지 않는다.
 - c 방식은 가장 간단하지만, 사후 확률 $P(C_k|\mathbf{x})$ 를 알 수 없다는 단점이 있다. 사후 확률을 알아야 위험 최소화, 거부 옵션 적용, 그리고 클래스 사전 확률에 대한 보상 등 유의미한 작업을 수행할 수 있기 때문이다.

4. 회귀 문제에서의 결정 이론

결정 이론은 분류 문제 외에도 회귀 문제(예: 곡선 피팅 문제)에도 적용된다.

- **회귀에서의 손실:** 회귀 문제에서는 $\mathbf{x}$ 에 대한 타깃 변수 t 의 추정값 $y(\mathbf{x})$ 를 선택해야 하며, 이 과정에서 손실 $L(t, y(\mathbf{x}))$ 가 발생한다. 목표는 평균(기대) 손실 $E[L]$ 을 최소화하는 것이다.
- **제곱 손실 (Squared Loss):** 회귀 문제에서 일반적으로 사용하는 손실 함수는 $L(t, y(\mathbf{x})) = \{y(\mathbf{x}) - t\}^2$ 로 주어지는 제곱 손실이다.
- **최적의 결정 규칙:** 제곱 손실을 최소화하는 최적의 예측 함수 $y(\mathbf{x})$ 는 $\mathbf{x}$ 가 주어졌을 때 t 의 조건부 평균 $E[t|\mathbf{x}]$ 로 주어진다. 이를 회귀 함수(regression function)라고 한다.
 - 이때 발생하는 기대 제곱 손실의 최솟값은 t 에 대한 분포의 분산(노이즈)과 관련되며, 이는 $y(\mathbf{x})$ 에 독립적이어서 더 이상 줄일 수 없는 내재적인 변동성을 표현한다.

Ch 1.6 정보 이론 (p.54)

정보 이론은 불확실성을 다루는 데 초점을 맞추며, 확률 변수의 상태를 결정짓는 데 필요한 정보량을 정량화하는 데 사용된다.

1. 정보량 (Information Quantity)

정보 이론은 이산 확률 변수 X 가 특정 값을 가지고 있음을 확인했을 때 **전해지는 정보량이 얼마만큼인지**를 다룬다.

- 정보량은 degree of surprise로 생각할 수 있다.
- **확률과의 관계:** 매우 일어날 가능성이 높은 사건이 일어났다는 사실보다, **일어나기 매우 힘든 사건이 발생했다는 사실**을 전해 들었을 때 더 많은 정보를 전달받게 된다. 따라서 정보량 측정 단위는 확률 분포 $p(x)$ 에 종속적이다.
- **결합 사건:** 서로 연관되어 있지 않은 두 사건 x 와 y 가 함께 일어났을 때 얻는 정보량은 각각의 사건이 따로 일어났을 때 얻는 정보량의 합이 되어야 한다. ($h(x, y) = h(x) + h(y)$)
- **수학적 정의:** 이러한 관계를 통해 정보량 $h(x)$ 는 확률 $p(x)$ 의 로그(log)에 해당한다는 것을 알 수 있으며, 다음과 같이 정의된다:

$$h(x) = -\log_2 p(x) \quad (\text{식 1.92})$$

- **단위:** 음의 부호는 정보량이 음의 값을 가지지 않도록 하며, 로그의 밑으로 2를 사용할 경우 $h(x)$ 의 단위는 비트가 된다. 사건 x 의 **확률이 낮을수록** 그로부터 얻을 수 있는 정보량은 커진다.

2. 엔트로피 (Entropy)

엔트로피 $H[x]$ 는 확률 변수 X 의 값을 수신자에게 전송하고자 할 때, **전송에 필요한 정보량의 평균치**이다. 이는 식 1.92의 정보량에 대한 기댓값을 구함으로써 얻어진다:

$$H[x] = -\sum_x p(x) \log_2 p(x) \quad (\text{식 1.93})$$

- **균일 분포와 엔트로피:** 균일 분포(모든 값이 같은 확률을 가짐)의 엔트로피가 비균일 분포의 엔트로피보다 더 높다. 이는 엔트로피를 **무질서의 척도**로서 해석하는 것과 연관된다.
- **코드 길이의 하한선:** noiseless coding theorem에 따르면, 엔트로피는 확률 변수의 상태를 전송하기 위해 필요한 비트 숫자의 **하한선**이다.
- **최대 엔트로피:** 엔트로피는 확률 분포가 변수의 가능한 상태에 대해 **고르게 분포되어 있을 때 최대가 된다**.
- **단위:** 엔트로피를 정의할 때 자연 로그(ln)를 사용하면 단위는 비트가 아닌 nats로 측정된다.
- **미분 엔트로피 (Differential Entropy)**
 - 연속 변수 x 에 대해 정의된 밀도 함수 $p(x)$ 의 경우에는 **미분 엔트로피**를 사용한다:

$$H[x] = - \int p(x) \ln p(x) dx \quad (\text{식 1.104})$$

- **가우시안 분포:** 미분 엔트로피의 최댓값을 구하기 위해 모멘트(1차, 2차) 및 정규화 상수에 제약 조건을 두면, 엔트로피를 최대화하는 분포는 가우시안 분포(Gaussian distribution)라는 것을 알 수 있다.
- **음수 가능성:** 미분 엔트로피는 이산 엔트로피와는 달리 **음의 값도 가질 수 있다**.
- **조건부 엔트로피 (Conditional Entropy)**
 - X 값과 Y 값을 함께 뽑는 결합 분포 $p(x, y)$ 가 있을 때, X 의 값이 이미 알려져 있다면, 그에 해당하는 Y 값을 알기 위해 추가로 필요한 정보의 평균값은 **조건부 엔트로피** $H[y|x]$ 로 주어진다.
 - X 와 Y 를 특정짓기 위해 필요한 정보의 양 $H[x, y]$ 는 X 만 따로 특정짓기 위해 필요한 정보의 양 $H[x]$ 와 X 가 주어졌을 때 Y 를 특정짓기 위해 필요한 정보의 양 $H[y|x]$ 를 합한 것과 같다:

$$H[x, y] = H[y|x] + H[x] \quad (\text{식 1.112})$$

3. 상대적 엔트로피와 상호 정보량

- 쿨백 라이블러 발산 (Kullback-Leibler Divergence, KL 발산)

- 알려지지 않은 실제 분포 $p(x)$ 를 추정하기 위해 모델 분포 $q(x)$ 를 만들었을 때, $q(x)$ 를 이용하여 코드를 만들면 $p(x)$ 대신 $q(x)$ 를 사용했으므로 추가 정보가 필요하다. 이 추가로 필요한 정보의 양을 **상대 엔트로피(Relative Entropy)** 또는 **쿨백 라이블러 발산** $KL(p||q)$ 이라고 부른다:

$$KL(p||q) = \int p(x) \ln \left(\frac{p(x)}{q(x)} \right) dx \quad (\text{식 1.113})$$

- 발산의 특징:

- $KL(p||q) \geq 0$ 이다.
- $KL(p||q) = 0$ 이 되는 것은 $p(x) = q(x)$ 인 것과 동치이다.
- 이는 두 분포 $p(x)$ 와 $q(x)$ 가 **얼마나 다른지의 척도**로 사용될 수 있다.

- **가능도 함수와의 관계:** 쿨백 라이블러 발산을 최소화하는 것은 분포 $q(x|\theta)$ 하에서의 **음의 로그 가능도 함수(negative log likelihood function)**를 최소화하는 것, 즉 가능도 함수를 최대화하는 것과 동일하다.

- **상호 정보량 (Mutual Information)**

- 두 변수 X 와 Y 의 결합 분포 $p(x, y)$ 와 주변 분포들의 곱 $p(x)p(y)$ 사이의 쿨백 라이블러 발산을 이용하여 두 변수가 '**얼마나**' 독립적인지를 알아볼 수 있다.
- **정의:** 이를 변수 X 와 Y 사이의 **상호 정보량** $I[x, y]$ 이라고 한다:

$$I[x, y] \equiv KL(p(x, y)||p(x)p(y)) \quad (\text{식 1.120})$$

- 독립성: $I[x, y] \geq 0$ 이며, X 와 Y 가 서로 독립적일 때만 $I[x, y] = 0$ 이다.
- 불확실성 감소: 상호 정보량은 $H[x] - H[y|x]$ 로 표현될 수 있으며, 베이시안 관점에서 새로운 관찰값 Y 의 결과로 줄어드는 X 에 대한 불확실성을 표현한 것이다.

Appendix. 수학적 지식

1. 변분법

숫자나 벡터에 대한 함수 $f(x)$ 의 극값을 찾는 것을 넘어 **함수 자체**를 변수로 삼아
함수의 함수(함수적) $J[y]$ 를 최소/최대로 만드는 **함수** $y(\cdot)$ 를 찾는 방법

$$J[y] = \int_a^b F(x, y(x), y'(x)) dx$$

- 예를 들어 ‘두 점을 잇는 곡선 중 길이가 최소가 되는 곡선(=직선)’을 구할 때 사용한다.

보통 최적화에서 “미분 = 0”이 극값의 필요조건이듯, **변분법에서는 EL = 0**이
극값의 필요조건이다.

2. 오일러-라그랑주 방정식 (EL)

후보 함수 y 를 아주 살짝 흔든 $y + \varepsilon \eta$ (여기서 $\eta(a) = \eta(b) = 0$)를 넣고, $\frac{d}{d\varepsilon} J[y + \varepsilon \eta] \Big|_{\varepsilon=0} = 0$ 이 모든 η 에 대해 성립하면, 그 y 가 극값을 준다는 조건

- 이를 전개하면 고전적인 EL 식이 나오게 된다.

$$\frac{\partial F}{\partial y} - \frac{d}{dx} \left(\frac{\partial F}{\partial y'} \right) = 0$$