

3.11 ★★ 데이터 집합의 크기가 증가함에 따라서 모델 매개변수의 사후 분산과 연관된 불확실성 정도가 감소한다는 것을 살펴봤었다. 식 3.110의 행렬 성질(부록 C)를 이용해서 식 3.59의 선형 회귀 함수와 연관된 불확실도 $\sigma_N^2(\mathbf{x})$ 가 식 3.111을 만족함을 증명하라.

$$(\mathbf{M} + \mathbf{v}\mathbf{v}^T)^{-1} = \mathbf{M}^{-1} - \frac{(\mathbf{M}^{-1}\mathbf{v})(\mathbf{v}^T\mathbf{M}^{-1})}{1 + \mathbf{v}^T\mathbf{M}^{-1}\mathbf{v}} \quad (\text{식 3.110})$$

$$\sigma_{N+1}^2(\mathbf{x}) \leq \sigma_N^2(\mathbf{x}) \quad (\text{식 3.111})$$

여기서 $\mathbf{t}$ 는 훈련 집합으로부터 주어진 표적값들의 벡터다. 이에 해당하는 입력 벡터들은 표기를 간단히 하기 위해서 조건절의 오른쪽 변으로부터 생략하였다. 조건부 분포 $p(\mathbf{t}|\mathbf{x}, \mathbf{w}, \beta)$ 는 식 3.8과 같이 주어지며, 사후 가중 분포는 식 3.49로 주어진다. 식 3.57은 두 가우시안 분포의 콘볼루션을 포함하고 있다. 따라서 식 2.115를 이용하면 예측 분포가 다음의 형태를 지닌다는 것을 구할 수 있다.

$$p(\mathbf{t}|\mathbf{x}, \mathbf{t}, \alpha, \beta) = \mathcal{N}(\mathbf{t}|\mathbf{m}_N^T\phi(\mathbf{x}), \sigma_N^2(\mathbf{x})) \quad (\text{식 3.58})$$

여기서 예측 분포의 분산 $\sigma_N^2(\mathbf{x})$ 는 다음과 같이 주어진다.

$$\sigma_N^2(\mathbf{x}) = \frac{1}{\beta} + \phi(\mathbf{x})^T \mathbf{S}_N \phi(\mathbf{x}) \quad (\text{식 3.59})$$

$$\mathbf{S}_N^{-1} = \mathbf{S}_0^{-1} + \beta \Phi^T \Phi \quad (\text{식 3.51})$$

$$\Phi^T \Phi = \sum_{n=1}^N \phi(\mathbf{x}_n) \phi(\mathbf{x}_n)^T \quad \therefore \text{각 데이터 포인트들의 2개의 합으로 풀어서 볼 수 있다.}$$

$$\begin{aligned} \mathbf{S}_{N+1}^{-1} &= \mathbf{S}_0^{-1} + \beta \sum_{n=1}^N \phi_n \phi_n^T + \beta \phi_{N+1} \phi_{N+1}^T \\ &= \mathbf{S}_N^{-1} + \beta \phi_{N+1} \phi_{N+1}^T \end{aligned}$$

$$\therefore \mathbf{M} = \mathbf{S}_N^{-1}, \mathbf{V} = \sqrt{\beta} \phi_{N+1}$$

$$\begin{aligned} \mathbf{S}_{N+1} &= (\mathbf{S}_N^{-1} + \beta \phi_{N+1} \phi_{N+1}^T)^{-1} \\ &= \mathbf{S}_N - \frac{(\mathbf{S}_N \sqrt{\beta} \phi_{N+1})(\sqrt{\beta} \phi_{N+1}^T \mathbf{S}_N)}{1 + \sqrt{\beta} \phi_{N+1}^T \mathbf{S}_N \sqrt{\beta} \phi_{N+1}} \end{aligned}$$

$$\mathbf{S}_N - \mathbf{S}_{N+1} = \frac{\beta (\mathbf{S}_N \phi_{N+1})(\phi_{N+1}^T \mathbf{S}_N)}{1 + \beta \phi_{N+1}^T \mathbf{S}_N \phi_{N+1}} \quad \text{이 대입}$$

$$\begin{aligned} \sigma_N^2(\mathbf{x}) - \sigma_{N+1}^2(\mathbf{x}) &= \left(\frac{1}{\beta} + \phi(\mathbf{x})^T \mathbf{S}_N \phi(\mathbf{x}) \right) - \left(\frac{1}{\beta} + \phi(\mathbf{x})^T \mathbf{S}_{N+1} \phi(\mathbf{x}) \right) \\ &= \phi(\mathbf{x})^T (\mathbf{S}_N - \mathbf{S}_{N+1}) \phi(\mathbf{x}) \\ &= \phi(\mathbf{x})^T \frac{\beta (\mathbf{S}_N \phi_{N+1})(\phi_{N+1}^T \mathbf{S}_N)}{1 + \beta \phi_{N+1}^T \mathbf{S}_N \phi_{N+1}} \phi(\mathbf{x}) \geq 0 \end{aligned}$$

$$\begin{aligned} \text{분자: } & \beta (\phi(\mathbf{x})^T \mathbf{S}_N \phi_{N+1})(\phi_{N+1}^T \mathbf{S}_N \phi(\mathbf{x})) \\ &= \beta (\phi(\mathbf{x})^T \mathbf{S}_N \phi_{N+1})^2 \quad \therefore \mathbf{S}_N \text{은 대칭행렬이므로, 결과값이 스칼라면 전치해도 결과가 변하지 않는다} \\ & \quad (\mathbf{S}_N^T = \mathbf{S}_N) \\ \therefore & \text{이보다 크거나 같다.} \end{aligned}$$

$$\text{분모: } 1 + \beta \phi_{N+1}^T \mathbf{S}_N \phi_{N+1}$$

$\mathbf{S}_N$ 은 사후 공분산 행렬로 양의 정부호 행렬이므로 $\mathbf{v}^T \mathbf{S}_N \mathbf{v} > 0$

β 도 양수 이이 아닌 모든 벡터 $\mathbf{v}$ 에 대해 이차 형식이 항상 양수이다.

$\therefore$ 1보다 큰 양수

$$\therefore \sigma_{N+1}^2(\mathbf{x}) \leq \sigma_N^2(\mathbf{x})$$

데이터가 많아질수록 모델의 불확실성 감소

3.14 ** 이 연습문제에서는 식 3.62에서 정의한 등가 커널의 성질에 대해 더 자세히 살펴볼 것이다. 여기서 S_N 은 식 3.54의 정의를 따를 것이다. 기저 함수 $\phi_j(\mathbf{x})$ 들이 선형적으로 독립적이며, 데이터 포인트의 숫자 N 이 기저 함수의 숫자 M 보다 크다고 하자. 또한, 기저 함수 중 하나는 상수라고 하자. 즉, $\phi_0(\mathbf{x}) = 1$ 이다. 기저 함수들을 적절히 선형 결합하면 같은 공간상에 펼쳐져 있지만 서로 직교하는 새로운 기저 집합 $\psi_j(\mathbf{x})$ 를 구성할 수 있다.

$$\sum_{n=1}^N \psi_j(\mathbf{x}_n) \psi_k(\mathbf{x}_n) = I_{jk} \quad \text{정규직교} \quad (\text{식 3.115})$$

여기서 I_{jk} 은 $j = k$ 면 1, 아니면 0 값을 가진다. 그리고 $\psi_0(\mathbf{x}) = 1$ 이라고 하자. $\alpha = 0$ 일 경우 등가 커널을 $k(\mathbf{x}, \mathbf{x}') = \psi(\mathbf{x})^T \psi(\mathbf{x}')$ 와 같이 적을 수 있음을 증명하라. 이때 $\psi = (\psi_0, \dots, \psi_{M-1})^T$ 이다. 이 결과를 이용해서 커널이 다음의 합산 제약 조건을 만족함을 증명하라.

$$\sum_{n=1}^N k(\mathbf{x}, \mathbf{x}_n) = 1 \quad (\text{식 3.116})$$

$\alpha = 0$ (사전 정보가 없음, 평평한 선 분포)

$$S_N^{-1} = \beta \Phi^T \Phi$$

새로운 기저 함수 $\psi_j(\mathbf{x})$ 는 원래 기저 함수들의 선형결합으로 만들어
 $\mathbf{x}_n$ 에 대해 정규직교 성질을 가진다.

$$1) k(\mathbf{x}, \mathbf{x}') = \psi(\mathbf{x})^T \psi(\mathbf{x}')$$

$$S_N = \frac{1}{\beta} (\Phi^T \Phi)^{-1}$$

$$k(\mathbf{x}, \mathbf{x}') = \phi(\mathbf{x})^T (\Phi^T \Phi)^{-1} \phi(\mathbf{x}')$$

새로운 기저 함수 도입)

$$\psi(\mathbf{x}) = L \phi(\mathbf{x}) \quad \therefore M \times M, \text{ 선형 결합}$$

$$\Psi = \Phi L^T \quad (\Psi \text{는 } N \text{번재 행에 } \psi(x_n)^T \text{인 } N \times M \text{ 행렬})$$

$$\sum_{n=1}^N \psi_j(x_n) \psi_k(x_n) = I_{jk}$$

정규직교 성질 이용)

$$\Psi^T \Psi = I$$

$$(L \Phi^T)(\Phi L^T) = I$$

$$L(\Phi^T \Phi)L^T = I$$

$$\Phi^T \Phi = L^{-1}(L^T)^{-1} = (L^T L)^{-1}$$

$$(\Phi^T \Phi)^{-1} = L^T L$$

기저 함수 변환)

$$k(\mathbf{x}, \mathbf{x}') = \phi(\mathbf{x})^T L^T L \phi(\mathbf{x}')$$

$$= (L \phi(\mathbf{x}))^T (L \phi(\mathbf{x}')) = \psi(\mathbf{x})^T \psi(\mathbf{x}')$$

이 장의 나머지 부분에서는 처리 과정을 단순화하기 위해서 특정 형태의 가우시안 사전 분포를 사용할 것이다. 바로 0을 평균으로 가지고 단일 정밀도 매개변수 α 에 의해 결정되는 등방 가우시안 분포다. 즉, 다음과 같다.

$$p(\mathbf{w}|\alpha) = \mathcal{N}(\mathbf{w}|\mathbf{0}, \alpha^{-1}\mathbf{I}) \quad (\text{식 3.52})$$

이에 해당하는 $\mathbf{w}$ 에 대한 사후 분포는 식 3.49를 바탕으로 다음처럼 주어진다.

$$\mathbf{m}_N = \beta S_N \Phi^T \mathbf{t} \quad (\text{식 3.53})$$

$$S_N^{-1} = \alpha \mathbf{I} + \beta \Phi^T \Phi \quad (\text{식 3.54})$$

여기서 S_N 은 식 3.51의 정의를 따른다. 포인트 $\mathbf{x}$ 에서의 예측 분포들의 평균은 훈련 집합 타깃 변수 t_n 들의 선형 결합으로 주어진다. 즉, 다음과 같이 적을 수 있다.

$$y(\mathbf{x}, \mathbf{m}_N) = \sum_{n=1}^N k(\mathbf{x}, \mathbf{x}_n) t_n \quad (\text{식 3.61})$$

여기서 함수 $k(\mathbf{x}, \mathbf{x}')$ 는 다음처럼 정의된다.

$$k(\mathbf{x}, \mathbf{x}') = \beta \phi(\mathbf{x})^T S_N \phi(\mathbf{x}') \quad (\text{식 3.62})$$

식 3.62는 평활 행렬(smoother matrix), 또는 등가 커널(equivalent kernel)이라고 알려져 있다. 훈련 집합 표적값들의 선형 결합을 입력받아서 예측값을 내는 이러한 회귀 함수는 선형 평활기(linear smoother)라고 부른다. 등가 커널은 입력값 $\mathbf{x}_n$ 에 종속적이다. 왜냐하면 S_N 의 정의에 $\mathbf{x}_n$ 이 포함되어 있기 때문이다. 기저 함수가 가우시안인 경우의 등가 커널에 대해 그림 3.10에 그려져 있다. 커널 함수 $k(\mathbf{x}, \mathbf{x}')$ 를 세 개의 서로 다른 $\mathbf{x}$ 값들에 대해서 $\mathbf{x}'$ 의 함수로 그렸다. 각각은 $\mathbf{x}$ 주변에서 지역화되어 있다. $y(\mathbf{x}, \mathbf{m}_N)$ 으로 주어지는 $\mathbf{x}$ 에서의 예측 분포는 표적값들의 가중 조합을 통해 구해지게 되는데, 이때 $\mathbf{x}$ 값에 근접할수록 더 높은 가중치를, $\mathbf{x}$ 값으로부터 더 멀리 떨어진수록 낮은 가중치를 가지게 된다. 직관적으로 봤을 때 지역적으로 가까이 있는 증거

$$2) \sum_{n=1}^N k(\mathbf{x}, \mathbf{x}_n) = 1$$

$$\sum_{n=1}^N k(\mathbf{x}, \mathbf{x}_n) = \sum_{n=1}^N \psi(\mathbf{x})^T \psi(\mathbf{x}_n) = \psi(\mathbf{x})^T \left(\sum_{n=1}^N \psi(\mathbf{x}_n) \right) \quad \text{← 선형결합}$$

$$\psi_0(\mathbf{x}) = 1 \text{ 이므로 } \sum_{n=1}^N \psi_0(\mathbf{x}_n) \psi_k(\mathbf{x}_n) = \sum_{n=1}^N \psi_k(\mathbf{x}_n) = 0$$

정규직교 성질에 의해, $j=0$ 일 때와 $k \neq 0$ 일 때 $\sum \psi_j \psi_k = 0$ 이어야 한다.

$$\sum_{n=1}^N \psi_k(\mathbf{x}_n) = 0, \quad k \neq 0 \text{ 일 때는 } 1$$

$$\begin{pmatrix} \sum \psi_0(\mathbf{x}_n) \\ \sum \psi_1(\mathbf{x}_n) \\ \vdots \end{pmatrix} \xrightarrow{\text{정규직교}} \begin{pmatrix} \sum \psi_0(\mathbf{x}_n) \\ 0 \\ \vdots \end{pmatrix}$$

$$\therefore \psi(\mathbf{x})^T \left(\sum_{n=1}^N \psi(\mathbf{x}_n) \right) = \begin{pmatrix} \psi_0(\mathbf{x}) \\ \psi_1(\mathbf{x}) \\ \vdots \end{pmatrix}^T \begin{pmatrix} \sum \psi_0(\mathbf{x}_n) \\ 0 \\ \vdots \end{pmatrix}$$

$$= \psi_0(\mathbf{x}) \times \left(\sum_{n=1}^N \psi_0(\mathbf{x}_n) \right)$$

$\psi_0(\mathbf{x}) = 1$ 이면? N 이 되어야 함

$$= \frac{1}{N} \text{ 이면? } 1 \text{ 이 됨.}$$