

3.3 * 각각의 데이터 포인트 t_n 가 가중 인자 $r_n > 0$ 와 연관되어 있는 데이터 집합을 고려해 보자.
이 경우 제공합 오류 함수는 다음이 된다.

$$E_D(\mathbf{w}) = \frac{1}{2} \sum_{n=1}^N r_n \{t_n - \mathbf{w}^T \phi(\mathbf{x}_n)\}^2 \quad (\text{식 3.104})$$

오류 제공합
r_n 가중

이 오류 함수를 최소화하는 해 $\mathbf{w}^*$ 에 대한 공식을 구하라. 이 가중된 제공합 오류 함수에 대한 다음의 두 가지 다른 해석을 내려 보아라.

- (i) 데이터에 종속적인 노이즈 분산
- (ii) 복제된 데이터 포인트

$$\mathbf{w}^* \quad \frac{\partial E_D}{\partial \mathbf{w}} = \frac{1}{2} \sum_{n=1}^N r_n \cdot 2(t_n - \mathbf{w}^T \phi_n) (-\phi_n) = - \sum_{n=1}^N r_n (t_n - \mathbf{w}^T \phi_n) \phi_n = 0$$

$$\sum r_n t_n \phi_n = \sum r_n (\mathbf{w}^T \phi_n) \phi_n = \sum r_n \phi_n \phi_n^T \mathbf{w}$$

$$\mathbf{w}^* = \left(\sum r_n \phi_n \phi_n^T \right)^{-1} \left(\sum r_n t_n \phi_n \right)$$

$$\Phi = [\phi_1^T \dots \phi_N^T]$$

$$\mathbf{t} = (t_1 \dots t_N)^T$$

$$\mathbf{R} = \text{diag}(r_1 \dots r_N)$$

오류함의 미분

$$E_D(\mathbf{w}) = \frac{1}{2} (\mathbf{t} - \Phi \mathbf{w})^T \mathbf{R} (\mathbf{t} - \Phi \mathbf{w})$$

$$\Phi^T \mathbf{R} \Phi \mathbf{w} = \Phi^T \mathbf{R} \mathbf{t}$$

$$\mathbf{w}^* = (\Phi^T \mathbf{R} \Phi)^{-1} \Phi^T \mathbf{R} \mathbf{t}$$

i)

$$t_n = \mathbf{w}^T \phi(\mathbf{x}_n) + \epsilon_n \quad \epsilon_n \sim N(0, \beta_n^{-1})$$

서로 다른 분산 가중치만 노이즈

$$P(t_n | \mathbf{x}_n, \mathbf{w}) = N(t_n | \mathbf{w}^T \phi(\mathbf{x}_n), \beta_n^{-1})$$

$$-\log P(\mathbf{t} | \mathbf{w}) = \frac{1}{2} \sum_{n=1}^N \beta_n (t_n - \mathbf{w}^T \phi(\mathbf{x}_n))^2$$

$E_D(\mathbf{w})$ 는 데이터의 노이즈 수준을 반영할 수 있다.

$\beta_n = r_n = \frac{1}{\sigma_n^2}$

$\downarrow$
분산의 역수

분산이 작아지면 r_n 이 커져서 오차에 가중치가 커짐.


ii) 노이즈 분산이 같으면...?

복제된 상황

$(\mathbf{x}_n, t_n)$ 이 k_n 번 반복되었다면

r_n 이 k_n 이 되면 된다.

이 상황에선 동량법으로 맞출 수 있다.



3.5 * [www](#) 부록 E의 라그랑주 승수법을 이용해서 식 3.29의 정규화된 오류 함수를 최소화하는 것이 식 3.12의 정규화되지 않은 곱합 오류를 식 3.30의 제약 조건하에서 최소화하는 것과 동일하다는 것을 증명하라. 그리고 매개변수 η 와 λ 의 관계에 대해 논하라.

$$\frac{1}{2} \sum_{n=1}^N \{t_n - \mathbf{w}^T \phi(\mathbf{x}_n)\}^2 + \frac{\lambda}{2} \sum_{j=1}^M |w_j|^q$$

3.29

$$\sum_{j=1}^M |w_j|^q \leq \eta$$

3.30

$$E_D(\mathbf{w}) = \frac{1}{2} \sum_{n=1}^N \{t_n - \mathbf{w}^T \phi(\mathbf{x}_n)\}^2$$

3.12

라그랑주 만들기

$$L(\mathbf{w}, \lambda) = E_D(\mathbf{w}) + \lambda (\|\mathbf{w}\|^2 - \eta)$$

미분

$$\nabla_{\mathbf{w}} L(\mathbf{w}, \lambda) = \nabla E_D(\mathbf{w}) + 2\lambda \mathbf{w} = 0$$

$$\nabla E_D(\mathbf{w}) + \lambda \mathbf{w} = 0 \quad \text{같다.}$$

아니
무엇일지
시도

3.12 ** 2.3.6절에서 평균과 정밀도(분산의 역)가 알려지지 않은 가우시안 분포에 대한 켄레 사전 분포가 정규 감마 분포라는 것을 보았다. 이 성질은 선형 회귀 모델의 조건부 가우시안 분포 $p(t|x, w, \beta)$ 에 대해서도 성립한다. 식 3.10의 가능도 함수를 고려한다면 w 와 β 에 대한 켄레 사전 분포는 다음처럼 주어지게 된다.

$$p(w, \beta) = \mathcal{N}(w|m_0, \beta^{-1}S_0) \text{Gam}(\beta|a_0, b_0) \quad (\text{식 3.112})$$

prior $\nwarrow$ $\nwarrow$ $\nwarrow$
 β w β 의 사전 분포

해당 사후 분포가 같은 함수적 형태를 가진다는 것을 증명하라. 즉, 다음을 증명하는 것이다.

$$p(w, \beta|t) = \mathcal{N}(w|m_N, \beta^{-1}S_N) \text{Gam}(\beta|a_N, b_N) \quad (\text{식 3.113})$$

$\nwarrow$
 β 의 사전 분포

그리고 사후 분포 매개변수 m_N, S_N, a_N, b_N 의 표현식을 유도해 보아라.

likelihood $\times$ prior = posterior

정규분포 곱 $-\frac{\beta}{2} (w-m_N)^T S_N^{-1} (w-m_N)$ 문 만들어보자.

$$p(w, \beta|t) \propto p(t|w, \beta) p(w, \beta)$$

$$\text{Posterior} \propto \left[\beta^{\frac{N}{2}} \exp\left(-\frac{\beta}{2} (t-\Phi w)^T (t-\Phi w)\right) \right] \times \left[\beta^{\frac{D}{2}} \exp\left(-\frac{\beta}{2} (w-m_0)^T S_0^{-1} (w-m_0)\right) \right] \times [\rho^{a_0} e^{-b_0 \rho}]$$

자바 내부에서 β 에 대한 미분식을 정리하면

$$-\frac{\beta}{2} \left[w^T (\Phi^T \Phi + S_0^{-1}) w - 2w^T (\Phi^T t + S_0^{-1} m_0) + \dots \right]$$

이 모양이 $-\frac{\beta}{2} (w-m_N)^T S_N^{-1} (w-m_N)$

$$= -\frac{\beta}{2} \left[w^T S_N^{-1} w - 2w^T S_N^{-1} m_N + m_N^T S_N^{-1} m_N \right]$$

같이야함 $\rightarrow$ 같이야함

$$\rightarrow S_N^{-1} = S_0^{-1} + \Phi^T \Phi$$

$$S_N^{-1} m_N = S_0^{-1} m_0 + \Phi^T t$$

$$m_N = S_N (S_0^{-1} m_0 + \Phi^T t)$$

S_N 과 m_N 을 구하면 사후분포가 Normal Gamma 분포임을 확인할 수 있다.

$$t = w^T \phi + \epsilon, \quad \epsilon \sim \mathcal{N}(0, \beta^{-1})$$

$$p(t|x, w, \beta) = \mathcal{N}(t|w^T \phi(x), \beta^{-1})$$

$$p(t|x, w, \beta) = \prod_{n=1}^N \mathcal{N}(t_n | w^T \phi(x_n), \beta^{-1}) \quad \text{식 3.10}$$

$$\propto \beta^{\frac{N}{2}} \exp\left(-\frac{\beta}{2} (t-\Phi w)^T (t-\Phi w)\right)$$