

머신러닝 깊게 이해하기

노트테이커: 박지원

주차: 2주차

일시: November, 2025

Ch 2.1 이산 확률 변수 (Discrete Random Variable)

1. 정의

이산 확률 변수란 **유한하거나 셀 수 있는 가능한 값**을 갖는 확률 변수이다. 예를 들어 동전 던지기에서 $x = 1$ 은 앞면, $x = 0$ 은 뒷면으로 정의할 수 있다. 성공 확률을 μ 라고 하면 다음과 같이 표현된다:

$$p(x = 1|\mu) = \mu, \quad p(x = 0|\mu) = 1 - \mu \quad (1)$$

2. 베르누이 분포 (Bernoulli Distribution)

하나의 시행에서 **성공** 또는 **실패** 두 가지 결과만 가능한 분포이다.

$$p(x|\mu) = \mu^x(1 - \mu)^{1-x}, \quad x \in \{0, 1\}, \quad 0 \leq \mu \leq 1 \quad (2)$$

기댓값과 분산:

$$\mathbb{E}[x] = \mu, \quad \text{var}[x] = \mu(1 - \mu) \quad (3)$$

가능도 함수(Likelihood):

$$p(D|\mu) = \prod_{n=1}^N p(x_n|\mu) = \mu^{\sum x_n} (1 - \mu)^{N - \sum x_n} \quad (4)$$

이를 최대화하면 최대우도추정(MLE)은 $\hat{\mu} = \frac{1}{N} \sum_{n=1}^N x_n$ 이 된다.

3. 이항 분포 (Binomial Distribution)

정의: N 번의 독립된 베르누이 시행에서 성공한 횟수 m 의 분포이다.

$$\text{Bin}(m|N, \mu) = \binom{N}{m} \mu^m (1 - \mu)^{N-m} \quad (5)$$

$$\binom{N}{m} = \frac{N!}{m!(N-m)!}$$

기댓값과 분산:

$$\mathbb{E}[m] = N\mu, \quad \text{var}[m] = N\mu(1 - \mu) \quad (6)$$

베르누이 분포는 단일 시행의 모델이며, 이를 여러 번 반복하면 이항 분포가 된다.

Ch 2.1.1 베타 분포 (Beta Distribution)

1. 개요

이항 분포에서 μ 의 최대 가능도 추정값은 데이터 내에서 $x = 1$ 인 관측값의 비율로 계산된다. 하지만 데이터의 수가 적을 때 과적합(overfitting)이 발생하기 쉽다.

이를 방지하고 베이저안적으로 접근하기 위해, μ 에 대한 사전 분포(prior distribution) $p(\mu)$ 를 도입한다. 이 사전 분포는 해석이 쉽고 수학적으로 다루기 편리해야 하며, 베르누이 분포의 형태와 곱셈 관계가 잘 맞아야 한다.

2. 정의

만약 μ 와 $(1 - \mu)$ 의 거듭제곱 형태를 갖는 분포를 사전 분포로 선택한다면, 사전 확률과 가능도 함수의 곱으로 얻은 사후 분포(posterior distribution) 역시 같은 형태를 유지한다. 이러한 성질을 결합성(conjugacy)이라고 한다.

이때 사용되는 사전 분포가 바로 **베타 분포(Beta Distribution)**이다.

$$\text{Beta}(\mu|a, b) = \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} \mu^{a-1} (1 - \mu)^{b-1} \quad (7)$$

여기서 $\Gamma(x)$ 는 감마 함수이며, 정규화 상수 역할을 한다.

3. 정규화 조건

베타 분포는 다음 조건을 만족하도록 정규화된다.

$$\int_0^1 \text{Beta}(\mu|a, b) d\mu = 1 \quad (8)$$

4. 평균과 분산

베타 분포의 평균과 분산은 다음과 같다:

$$\mathbb{E}[\mu] = \frac{a}{a+b} \quad (9)$$

$$\text{var}[\mu] = \frac{ab}{(a+b)^2(a+b+1)} \quad (10)$$

매개변수 a 와 b 는 μ 의 분포를 조절하는 **초매개변수(hyperparameter)**로 불린다.

5. 요약

베타 분포는 베르누이 및 이항 분포의 사전 분포로 자주 사용되며, 결합성을 통해 사후 분포 또한 같은 형태를 유지한다. 이로 인해 베이저안 추론에서 매우 유용한 분포로 쓰인다.

Ch 2.2 다항 변수 (Multinomial Variable)

1. 개요

이산 확률 변수는 두 가지 가능한 값 중 하나를 취하는 수량을 설명하는 데 사용된다. 하지만 경우에 따라서는 서로 다른 K 개의 값 중 하나를 취할 수 있는 **다항 변수(multinomial variable)**를 사용해야 한다.

예를 들어, 동전 던지기(앞/뒤)는 이항 변수이지만, 주사위 던지기(1~6)는 다항 변수에 해당한다.

2. 원 핫 인코딩 (One-Hot Encoding)

이러한 변수를 표현하는 여러 방법 중 원 핫 인코딩(one-hot encoding)은 각종 응용에서 다루기 편리하다.

원 핫 인코딩에서는 각 변수 x 가 K 차원의 벡터로 표현된다. 이때 특정 상태 k 가 선택되면 $x_k = 1$ 이 되고, 나머지 모든 성분은 0으로 설정된다.

$$\mathbf{x} = (0, 0, 1, 0, 0, 0)^T \quad (11)$$

예를 들어, 여섯 가지 상태 중 세 번째 상태($x_3 = 1$)인 경우 위와 같이 표현된다.

3. 다항 변수의 확률 모델

다항 변수의 확률분포는 한 번의 시행에서 여러 범주 중 하나가 선택될 확률을 나타낸다. 이를 다항 분포(multinomial distribution)라고 한다. K 개의 가능한 결과 각각에 대한 확률을 $\mu_1, \mu_2, \dots, \mu_K$ 로 나타내며, 이 값들은 모두 양수이고 다음을 만족해야 한다:

$$\sum_{k=1}^K \mu_k = 1 \quad (12)$$

4. 정의

하나의 관측 $\mathbf{x}$ 가 주어졌을 때 다항 분포는 다음과 같이 정의된다:

$$p(\mathbf{x}|\boldsymbol{\mu}) = \prod_{k=1}^K \mu_k^{x_k} \quad (13)$$

여기서 $x_k \in \{0, 1\}$ 이며, $\sum_{k=1}^K x_k = 1$ 이다. 즉, $\mathbf{x}$ 는 어떤 한 상태만 1이고 나머지는 0인 벡터(one-hot vector)이다.

5. 요약

다항 변수는 이항 변수의 일반화된 형태로, $K = 2$ 일 때는 베르누이 분포가 된다. 즉, 다항 분포는 여러 범주 중 하나를 선택하는 확률 모델로서, 자연스럽게 베르누이 분포를 포함한다.

Ch 2.2.1 디리클레 분포 (Dirichlet Distribution)

핵심 요약

디리클레 분포(Dirichlet distribution)는 여러 개의 확률의 합이 1이 되도록 제약된 상황에서 이 확률들이 어떤 값을 가질지를 나타내는 확률 분포이다.

1. 정의

K 개의 확률 $\boldsymbol{\mu} = (\mu_1, \mu_2, \dots, \mu_K)$ 가

$$0 \leq \mu_k \leq 1, \quad \sum_{k=1}^K \mu_k = 1$$

을 만족할 때, 디리클레 분포는 다음과 같이 정의된다:

$$\text{Dir}(\boldsymbol{\mu}|\boldsymbol{\alpha}) = \frac{\Gamma(\sum_k \alpha_k)}{\prod_k \Gamma(\alpha_k)} \prod_{k=1}^K \mu_k^{\alpha_k-1} \quad (14)$$

2. 의미

- 각 α_k 는 해당 확률 μ_k 의 “가중치” 역할을 한다. $\rightarrow$ 값이 클수록 그 확률이 더 클 가능성이 높다.
- $\sum_k \mu_k = 1$ 제약 때문에 모든 확률은 서로 영향을 준다.
- 베타 분포는 디리클레 분포의 $K = 2$ 인 특수한 경우이다.

3. 역할

디리클레 분포는 **다항 분포의 사전 분포(conjugate prior)**로 사용된다. 즉, 다항 분포의 매개변수(각 범주의 확률)에 대한 불확실성을 표현할 때 쓰인다.

정리: 디리클레 분포는 여러 개의 확률이 동시에 1이 되는 상황(예: 주사위 확률)을 표현하며, 베타 분포의 다차원 확장판이다.

Ch 2.3 가우시안 분포 (Gaussian Distribution)

1. 개요

가우시안 분포(정규 분포)는 연속 확률 변수의 분포를 모델링할 때 가장 널리 쓰이는 분포이다. 데이터의 중심 근처에 값이 몰려 있고, 평균에서 멀어질수록 확률이 작아지는 형태를 가진다.

2. 단변량 가우시안 분포

하나의 실수형 변수 x 에 대한 가우시안 분포는 다음과 같다:

$$\mathcal{N}(x|\mu, \sigma^2) = \frac{1}{(2\pi\sigma^2)^{1/2}} \exp\left(-\frac{1}{2\sigma^2}(x - \mu)^2\right) \quad (15)$$

여기서 μ 는 평균, σ^2 는 분산을 나타낸다.

3. 다변량 가우시안 분포

D 차원 벡터 $\mathbf{x}$ 에 대해, 평균 벡터 $\boldsymbol{\mu}$ 와 공분산 행렬 $\boldsymbol{\Sigma}$ 를 사용하면:

$$\mathcal{N}(\mathbf{x}|\boldsymbol{\mu}, \boldsymbol{\Sigma}) = \frac{1}{(2\pi)^{D/2}|\boldsymbol{\Sigma}|^{1/2}} \exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu})\right) \quad (16)$$

$\boldsymbol{\mu}$ 는 평균 벡터, $\boldsymbol{\Sigma}$ 는 $D \times D$ 공분산 행렬이며 $|\boldsymbol{\Sigma}|$ 는 그 행렬식(determinant)이다.

4. 중심극한정리 (Central Limit Theorem)

여러 독립된 확률 변수들의 합은, 각각의 분포가 무엇이든 간에 그 개수가 충분히 많아지면 가우시안 분포에 근사하게 된다.

즉, N 개의 독립 변수 $x_1, x_2, \dots, x_N$ 이 있을 때 그 평균 $\frac{1}{N} \sum_{i=1}^N x_i$ 는 N 이 커질수록 가우시안 형태에 가까워진다.

$$x_i \in [0, 1] \Rightarrow \frac{x_1 + x_2 + \dots + x_N}{N} \approx \mathcal{N}(\mu, \sigma^2/N)$$

이 성질 덕분에 가우시안 분포는 많은 현실 데이터의 근사 모델로 사용된다.

5. 특징 요약

- 중심에 대한 대칭 형태를 가진다.
- 평균 μ 가 중심 위치, 분산 σ^2 가 퍼짐 정도를 결정한다.
- 여러 변수의 합은 가우시안으로 수렴한다 (중심극한정리).
- 다변량의 경우, 공분산 행렬을 통해 변수 간 상관관계를 표현한다.

요약: 가우시안 분포는 가장 기본적이고 강력한 연속 확률 분포로, 많은 데이터가 평균을 중심으로 분포할 때 자연스럽게 등장한다.

6. 마할라노비스 거리 (Mahalanobis Distance)

가우시안 분포의 기하학적 형태를 살펴보면, x 가 평균 μ 로부터 얼마나 떨어져 있는지를 나타내는 척도로 **마할라노비스 거리(Mahalanobis distance)**를 정의할 수 있다.

$$\Delta^2 = (\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}) \quad (17)$$

이 값은 $\mathbf{x}$ 가 평균으로부터 떨어진 “거리”를 공분산 $\boldsymbol{\Sigma}$ 로 보정하여 측정한 것이다. 즉, 분포의 형태(방향성, 분산의 크기)에 따라 스케일이 달라지는 거리이다.

- $\boldsymbol{\Sigma}$ 가 항등 행렬일 경우 $\rightarrow$ 유클리드 거리(Euclidean distance)와 동일.
- Δ^2 가 일정한 공간의 점들은 동일한 확률밀도를 가지며, 이는 **가우시안 분포의 등확률 곡선(ellipsoid)**을 형성한다.

7. 야코비안 (Jacobian)

변수 변환에서 확률밀도함수를 유지하기 위해서는, 새로운 좌표계 $(y_1, y_2, \dots, y_D)$ 로의 변환 시 변화율을 반영하는 **야코비안 행렬(Jacobian matrix)**이 필요하다.

$$J_{ij} = \frac{\partial x_i}{\partial y_j} \quad (18)$$

이는 $\mathbf{x}$ 좌표계에서 $\mathbf{y}$ 좌표계로 변환할 때의 기하학적 스케일 변화를 나타내며, 확률밀도함수의 보존식은 다음과 같이 표현된다:

$$p(\mathbf{x}) d\mathbf{x} = p(\mathbf{y}) |\det(\mathbf{J})| d\mathbf{y}$$

즉, 야코비안의 행렬식 $|\det(\mathbf{J})|$ 이 확률밀도의 변환 시 “부피 스케일 조정” 역할을 한다.

요약:

- 마할라노비스 거리: 평균과 공분산을 고려한 “일반화된 거리”
- 야코비안: 좌표 변환 시 확률밀도의 스케일을 조정하는 행렬