

머신러닝 깊게 이해하기

노트테이커: 김명석

주차: 4주차

일시: 5th, November

Ch 2.3 가우시안 분포

2.3.0 정의 및 속성

D차원 벡터 $\mathbf{x}$ 에 대한 다변량 가우시안 분포는 다음과 같이 정의된다.

$$\mathcal{N}(\mathbf{x}|\boldsymbol{\mu}, \boldsymbol{\Sigma}) = \frac{1}{(2\pi)^{D/2}} \frac{1}{|\boldsymbol{\Sigma}|^{1/2}} \exp \left\{ -\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu}) \right\} \quad (1)$$

여기서 $\boldsymbol{\mu}$ 는 D차원 평균 벡터, $\boldsymbol{\Sigma}$ 는 $D \times D$ 공분산 행렬이다. 지수부에 있는 이차 형식은 **마할라노비스 거리**의 제곱으로 정의된다.

$$\Delta^2 = (\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu}) \quad (2)$$

가우시안의 기하학적 형태를 이해하기 위해 공분산 행렬 $\boldsymbol{\Sigma}$ 의 고유벡터 분해 $\boldsymbol{\Sigma}^{-1} = \sum_{i=1}^D \frac{1}{\lambda_i} \mathbf{u}_i \mathbf{u}_i^T$ 를 활용한다. $y_i = \mathbf{u}_i^T(\mathbf{x} - \boldsymbol{\mu})$ 로 좌표를 변환하면, 마할라노비스 거리는 다음과 같이 단순화된다.

$$\Delta^2 = \sum_{i=1}^D \frac{y_i^2}{\lambda_i} \quad (3)$$

이는 확률 밀도가 $\boldsymbol{\mu}$ 를 중심으로 하고, 주축이 고유벡터 $\mathbf{u}_i$ 방향인 타원체 표면상에서 상수가 됨을 의미한다. 분포의 1차, 2차 모멘트는 매개변수와 직접 대응된다.

$$\mathbb{E}[\mathbf{x}] = \boldsymbol{\mu} \quad (4)$$

$$\text{cov}[\mathbf{x}] = \mathbb{E}[(\mathbf{x} - \mathbb{E}[\mathbf{x}])(\mathbf{x} - \mathbb{E}[\mathbf{x}])^T] = \boldsymbol{\Sigma} \quad (5)$$

2.3.1 조건부 가우시안 분포

가우시안 분포의 중요한 성질은 결합 분포가 가우시안일 때, 조건부 분포 역시 가우시안이라는 점이다. 이를 확인하기 위해 벡터 $\mathbf{x}$ 를 $\mathbf{x}_a$ 와 $\mathbf{x}_b$ 로 분할한다.

평균, 공분산, 그리고 정밀도 행렬 $\Lambda = \Sigma^{-1}$ 를 다음과 같이 분할한다.

$$\mathbf{x} = \begin{pmatrix} \mathbf{x}_a \\ \mathbf{x}_b \end{pmatrix}, \quad \boldsymbol{\mu} = \begin{pmatrix} \boldsymbol{\mu}_a \\ \boldsymbol{\mu}_b \end{pmatrix}, \quad \Sigma = \begin{pmatrix} \Sigma_{aa} & \Sigma_{ab} \\ \Sigma_{ba} & \Sigma_{bb} \end{pmatrix}, \quad \Lambda = \begin{pmatrix} \Lambda_{aa} & \Lambda_{ab} \\ \Lambda_{ba} & \Lambda_{bb} \end{pmatrix} \quad (6)$$

조건부 분포 $p(\mathbf{x}_a|\mathbf{x}_b)$ 는 결합 분포의 지수부에서 $\mathbf{x}_a$ 에 대한 항을 묶는 ”제곱식의 완성”을 통해 유도할 수 있다. 그 결과 역시 가우시안 분포이다.

유도된 평균과 공분산은 정밀도 행렬을 사용하거나, 분할 행렬의 역행렬 공식을 사용하여 공분산 행렬로 표현할 수 있다.

정밀도 행렬로 표현 시:

$$\Sigma_{a|b} = \Lambda_{aa}^{-1} \quad (7)$$

$$\boldsymbol{\mu}_{a|b} = \boldsymbol{\mu}_a - \Lambda_{aa}^{-1} \Lambda_{ab} (\mathbf{x}_b - \boldsymbol{\mu}_b) \quad (8)$$

공분산 행렬로 표현 시:

$$\mathbb{E}[\mathbf{x}_a|\mathbf{x}_b] = \boldsymbol{\mu}_{a|b} = \boldsymbol{\mu}_a + \Sigma_{ab} \Sigma_{bb}^{-1} (\mathbf{x}_b - \boldsymbol{\mu}_b) \quad (9)$$

$$\text{cov}[\mathbf{x}_a|\mathbf{x}_b] = \Sigma_{a|b} = \Sigma_{aa} - \Sigma_{ab} \Sigma_{bb}^{-1} \Sigma_{ba} \quad (10)$$

이 결과의 핵심은 조건부 평균이 $\mathbf{x}_b$ 의 선형 함수이고, 공분산은 $\mathbf{x}_b$ 와 독립이라는 점이다.

2.3.2 주변 가우시안 분포

조건부 분포와 마찬가지로, 주변 분포 $p(\mathbf{x}_a) = \int p(\mathbf{x}_a, \mathbf{x}_b) d\mathbf{x}_b$ 역시 가우시안 분포이다. 이는 결합 분포를 $\mathbf{x}_b$ 에 대해 적분하여 얻을 수 있으며, 그 결과는 매우 직관적이다.

$$\mathbb{E}[\mathbf{x}_a] = \boldsymbol{\mu}_a \quad (11)$$

$$\text{cov}[\mathbf{x}_a] = \boldsymbol{\Sigma}_{aa} \quad (12)$$

결과적으로, 조건부 분포는 정밀도 행렬로, 주변 분포는 공분산 행렬로 표현할 때 가장 단순한 형태가 된다.

2.3.3 가우시안 변수에 대한 베이지안 정리

앞선 두 절의 결과는 선형 가우시안 모델에 대한 베이지안 추론에 직접 적용된다. $p(\mathbf{x})$ 를 사전 분포로, $p(\mathbf{y}|\mathbf{x})$ 를 가능도 함수로 가정한다.

$$p(\mathbf{x}) = \mathcal{N}(\mathbf{x}|\boldsymbol{\mu}, \boldsymbol{\Lambda}^{-1}) \quad (13)$$

$$p(\mathbf{y}|\mathbf{x}) = \mathcal{N}(\mathbf{y}|\mathbf{A}\mathbf{x} + \mathbf{b}, \mathbf{L}^{-1}) \quad (14)$$

이 모델에서, 주변 분포 $p(\mathbf{y})$ 와 사후 분포 $p(\mathbf{x}|\mathbf{y})$ 또한 가우시안 분포가 된다.

$$p(\mathbf{y}) = \mathcal{N}(\mathbf{y}|\mathbf{A}\boldsymbol{\mu} + \mathbf{b}, \mathbf{L}^{-1} + \mathbf{A}\boldsymbol{\Lambda}^{-1}\mathbf{A}^T) \quad (15)$$

$$p(\mathbf{x}|\mathbf{y}) = \mathcal{N}(\mathbf{x}|\boldsymbol{\Sigma}\{\mathbf{A}^T\mathbf{L}(\mathbf{y} - \mathbf{b}) + \boldsymbol{\Lambda}\boldsymbol{\mu}\}, \boldsymbol{\Sigma}) \quad (16)$$

여기서 사후 분포의 공분산은 $\boldsymbol{\Sigma} = (\boldsymbol{\Lambda} + \mathbf{A}^T\mathbf{L}\mathbf{A})^{-1}$ 이다.

2.3.4 가우시안 분포의 최대 가능도

데이터 $X = \{\mathbf{x}_1, \dots, \mathbf{x}_N\}$ 가 주어졌을 때, 로그 가능도 함수를 최대화하는 매개변수는 미분을 통해 찾을 수 있다.

$$\boldsymbol{\mu}_{ML} = \frac{1}{N} \sum_{n=1}^N \mathbf{x}_n \quad (17)$$

$$\boldsymbol{\Sigma}_{ML} = \frac{1}{N} \sum_{n=1}^N (\mathbf{x}_n - \boldsymbol{\mu}_{ML})(\mathbf{x}_n - \boldsymbol{\mu}_{ML})^T \quad (18)$$

$\boldsymbol{\mu}_{ML}$ 은 비편향 추정값이지만, $\boldsymbol{\Sigma}_{ML}$ 은 $\mathbb{E}[\boldsymbol{\Sigma}_{ML}] = \frac{N-1}{N}\boldsymbol{\Sigma}$ 이므로 편향되어 있다. 공분산에 대한 비편향 추정값은 다음과 같다.

$$\tilde{\boldsymbol{\Sigma}} = \frac{1}{N-1} \sum_{n=1}^N (\mathbf{x}_n - \boldsymbol{\mu}_{ML})(\mathbf{x}_n - \boldsymbol{\mu}_{ML})^T \quad (19)$$

2.3.5 순차 추정

최대 가능도 해는 데이터가 순차적으로 들어올 때마다 갱신할 수 있다. 평균 $\boldsymbol{\mu}_{ML}$ 의 순차적 갱신식은 다음과 같다.

$$\boldsymbol{\mu}_{ML}^{(N)} = \boldsymbol{\mu}_{ML}^{(N-1)} + \frac{1}{N}(\mathbf{x}_N - \boldsymbol{\mu}_{ML}^{(N-1)}) \quad (20)$$

이는 회귀 함수 $f(\theta) \equiv \mathbb{E}[z|\theta]$ 의 근 $f(\theta^*) = 0$ 을 찾는 일반적인 순차 방법론인 **로빈스-몬로** 알고리즘의 한 예시이다.

$$\theta^{(N)} = \theta^{(N-1)} - a_{N-1}z(\theta^{(N-1)}) \quad (21)$$

최대 가능도 추정은 $\mathbb{E}_x[-\frac{\partial}{\partial \theta} \ln p(x|\theta)] = 0$ 의 근을 찾는 것과 같으므로, 이 알고리즘을 적용할 수 있다.

2.3.6 가우시안 분포에서의 베이지안 추론

매개변수 자체에 대한 사전 분포를 도입하여 베이지안 추론을 수행한다. *켈레* 사전 분포를 사용하면 사후 분포가 사전 분포와 동일한 함수 형태를 가진다.

- 분산 σ^2 이고, 평균 μ 미지수:

사전 분포로 **가우시안**을 사용하면, 사후 분포 역시 가우시안이 된다. 사후 분포의 정밀도는 사전 분포의 정밀도와 데이터의 정밀도의 합으로, 가산적이다.

$$\frac{1}{\sigma_N^2} = \frac{1}{\sigma_0^2} + \frac{N}{\sigma^2} \quad (22)$$

- 평균 μ 이고, 정밀도 λ 미지수:

사전 분포로 **감마 분포** $p(\lambda) = \text{Gam}(\lambda|a_0, b_0)$ 를 사용하면, 사후 분포 $p(\lambda|X)$ 역시 감마 분포 $\text{Gam}(\lambda|a_N, b_N)$ 가 된다.

$$a_N = a_0 + \frac{N}{2} \quad (23)$$

$$b_N = b_0 + \frac{1}{2} \sum_{n=1}^N (x_n - \mu)^2 \quad (24)$$

- 평균 μ , 정밀도 Λ 모두 미지수 (다변량):

켈레 사전 분포는 **정규-위샤트 분포** $p(\boldsymbol{\mu}, \boldsymbol{\Lambda}) = \mathcal{N}(\boldsymbol{\mu}|\boldsymbol{\mu}_0, (\beta\boldsymbol{\Lambda})^{-1})\mathcal{W}(\boldsymbol{\Lambda}|\mathbf{W}, \nu)$ 이다.

2.3.7 스튜던트 t-분포

t-분포는 가우시안 분포와 밀접한 관련이 있다. 단변량 가우시안 $\mathcal{N}(x|\mu, \tau^{-1})$ 의 정밀도 τ 가 감마 분포 $\text{Gam}(\tau|a, b)$ 를 따른다고 가정하고, 이 정밀도를 적분하여 소거하면 **스튜던트 t-분포**를 얻는다.

$$p(x|\mu, a, b) = \int_0^\infty \mathcal{N}(x|\mu, \tau^{-1})\text{Gam}(\tau|a, b)d\tau = \text{St}(x|\mu, \lambda, \nu) \quad (25)$$

이는 t-분포가 동일한 평균을 갖는 **무한한 수의 가우시안 분포의 혼합**임을 의미한다. t-분포는 가우시안보다 두꺼운 꼬리를 가지므로, outlier에 대해 **강건성**을 가진다.

2.3.8 주기적 변수

풍향과 같은 주기적 변수는 일반 가우시안으로 모델링하기 어렵다. 원점의 선택에 따라 평균과 분산이 크게 달라지기 때문이다. 대신 **폰 미제스 분포**를 사용한다.

$$p(\theta|\theta_0, m) = \frac{1}{2\pi I_0(m)} \exp\{m \cos(\theta - \theta_0)\} \quad (26)$$

여기서 θ_0 는 평균 방향, m 은 집중 매개변수(가우시안의 정밀도와 유사), $I_0(m)$ 은 0차 1종 베셀 함수이다.

평균 방향의 최대 가능도 추정값은 다음과 같다.

$$\bar{\theta} = \tan^{-1} \left\{ \frac{\sum_n \sin \theta_n}{\sum_n \cos \theta_n} \right\} \quad (27)$$

2.3.9 가우시안 혼합 모델

단일 가우시안은 단봉 분포(unimodal)만 표현할 수 있다. 실제 데이터에 존재하는 다봉 분포(multimodal)를 모델링하기 위해, 여러 개의 가우시안 분포를 선형 결합한다.

$$p(\mathbf{x}) = \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x}|\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \quad (28)$$

π_k 는 $\sum_k \pi_k = 1$ 을 만족하는 혼합 계수이다. 이 모델은 잠재 변수 k 를 도입하여 확률적으로 해석할 수 있다. 데이터 $\mathbf{x}$ 가 k 번째 성분에서 생성되었을 사후 확률을 **책임값**이라 부른다.

$$\gamma_k(\mathbf{x}) \equiv p(k|\mathbf{x}) = \frac{p(k)p(\mathbf{x}|k)}{\sum_l p(l)p(\mathbf{x}|l)} = \frac{\pi_k \mathcal{N}(\mathbf{x}|\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)}{\sum_l \pi_l \mathcal{N}(\mathbf{x}|\boldsymbol{\mu}_l, \boldsymbol{\Sigma}_l)} \quad (29)$$

매개변수를 추정하기 위한 로그 가능도 함수는 로그 안에 합계가 포함되어, 최대 가능도 해를 한 번에 풀 수 없다. 따라서 EM 알고리즘 같은 반복적 방법이 필요하다.

$$\ln p(X|\pi, \mu, \Sigma) = \sum_{n=1}^N \ln \left\{ \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x}_n|\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \right\} \quad (30)$$